# Named Tensors: Transformer

FFN

$$X \in \mathbb{R}^{\mathsf{emb}:d_{\mathsf{model}}}$$
 
$$W^1 \in \mathbb{R}^{\mathsf{emb}:d_{\mathsf{model}},\mathsf{hid}:d_{\mathsf{ff}}} \qquad \qquad b^1 \in \mathbb{R}^{\mathsf{hid}:d_{\mathsf{ff}}}$$
 
$$W^2 \in \mathbb{R}^{\mathsf{hid}:d_{\mathsf{ff}},\mathsf{emb}:d_{\mathsf{model}}} \qquad \qquad b^2 \in \mathbb{R}^{\mathsf{hid}:d_{\mathsf{ff}}}$$
 
$$\mathsf{FFN}(X;W,b) = W^2 \underset{\mathsf{hid}}{\cdot} \mathsf{ReLU}(W^1 \underset{\mathsf{emb}}{\cdot} X + b^1) + b^2$$

#### **Masked Attention**

$$Q \in \mathbb{R}^{\mathsf{key}:d_k,\mathsf{seq}':n}, K \in \mathbb{R}^{\mathsf{key}:d_k,\mathsf{seq}:n}$$

$$V \in \mathbb{R}^{\mathsf{seq}:n,\mathsf{val}:d_vfg}, M \in \mathbb{R}^{\mathsf{seq},\mathsf{seq}'}$$

$$\mathsf{att}(Q,K,V,M) = V \cdot \underset{\mathsf{seq}}{\bullet} \operatorname{softmax} \left( \frac{Q \cdot K}{\sqrt{d_k}} + M \right)$$

 $W^Q \in \mathbb{R}^{\mathsf{head}:h,\mathsf{emb}:d_{\mathrm{model}},\mathsf{key}:d_k}$ 

# Multiheaded Self Attention

Layer Norm

$$X \in \mathbb{R}^{\mathsf{emb}:d_{\mathsf{model}}} \qquad \qquad \gamma,\beta \in \mathbb{R}^{\mathsf{emb}:d_{\mathsf{model}}}$$
 
$$\mathsf{lnorm}(X;\gamma,\beta) = \frac{X - \underset{\mathsf{emb}}{\mathsf{mean}}(X)}{\sqrt{\operatorname*{var}(X)} + \epsilon} \odot \gamma + \beta$$

## **Position Encoding**

$$X \in \{0,1\}^{\mathsf{seq}:n,\mathsf{vocab}:b}$$
 
$$\sum_{\mathsf{vocab}} X = 1$$
 
$$E \in \mathbb{R}^{\mathsf{vocab}*:v,\mathsf{emb}:d_{\mathsf{model}}}$$
 
$$\mathsf{embed}(X;E) = (E \underset{\mathsf{vocab}}{\cdot} X) \sqrt{d_{\mathsf{model}}} + P$$
 
$$P \in \mathbb{R}^{\mathsf{seq}:n,\mathsf{hidden}:d_{\mathsf{model}}}$$
 
$$P_{\mathsf{hidden}:i,\mathsf{seq}:p} = \begin{cases} \sin((p-1)/10000^{(i-1)/d_{\mathsf{model}}}) & i \text{ odd} \\ \cos((p-1)/10000^{(i-2)/d_{\mathsf{model}}}) & i \text{ even} \end{cases}$$

### Transformer

$$\begin{split} I &\in \{0,1\}^{\text{seq}:n,\text{vocab}:b} \\ X^0 &= \text{embed}(I) \\ T^1 &= \text{lnorm}(\text{MHA}(X^0)) + X^0 \\ X^1 &= \text{lnorm}(\text{FFN}(T^1)) + T^1 \\ & \vdots \\ T^L &= \text{lnorm}(\text{MHA}(X^{L-1})) + X^{L-1} \\ X^L &= \text{lnorm}(\text{FFN}(T^L)) + T^L \\ O &= \text{softmax}(W \cdot X^L) \\ \text{emb} \end{split}$$